

# 《模式识别与机器学习》

## 第1次习题课

助教：许修为、黄原辉

2023年11月12日

## □ 填空题

- **注意：**概念题用尽量精简的话进行回答，可以参考教材的定义；简答题意思正确即可

### 一、填空题

1. LDA 线性判别分析的求解过程是将  $N$  维特征向量投影在\_\_\_\_\_维空间中进行。

答案：不超过  $C-1$ ， $C$  为类别总数

2. 对数几率函数  $\theta(x) =$  \_\_\_\_\_，其导数  $\theta'(x) =$  \_\_\_\_\_（可用  $\theta(x)$  表示）。

答案： $\frac{1}{1+e^{-x}}$ ； $\theta(x)(1-\theta(x))$

3. 散度越大，说明两类模式分布差异\_\_\_\_\_。

答案：越大

4. 散度是根据\_\_\_\_\_构造的可分性判据。

答案：类概率密度

5. 线性判别函数的正负和数值大小的几何意义是\_\_\_\_\_。

答案：正（负）表示样本点位于判别界面法向量指向的正（负）半空间中；绝对值正比于样本点到判别界面的距离

## □ 计算题

- **注意：**题目较为简单，直接代入公式即可。最后结果尽量用分数表示，或者用高精度（3-4位）小数，避免因精度太低丢分

### 二、计算题

两类数据如下所示：  $X_1 = (x_1, x_2) = \{(4,1), (2,4), (2,3), (3,6), (4,4)\}$ ，  $X_2 = (x_1, x_2) = \{(9,10), (6,8), (9,5), (8,7), (10,8)\}$ ，计算 LDA 的投影方向。

答案：

计算类均值：

$$\mu_1 = [3.0, 3.6]^T \quad \mu_2 = [8.4, 7.6]^T$$

计算类内散度矩阵：

$$S_w = \Sigma_0 + \Sigma_1 = \sum_{x \in X_1} (x - \mu_1)(x - \mu_1)^T + \sum_{x \in X_2} (x - \mu_2)(x - \mu_2)^T = \begin{bmatrix} 13.2 & -2.2 \\ -2.2 & 26.4 \end{bmatrix}$$

计算 LDA 投影方向：

$$w = S_w^{-1}(\mu_0 - \mu_1) = \left[ -\frac{344}{781}, -\frac{147}{781} \right]^T \approx [-0.44, -0.19]^T$$

## □ 证明题

### 三、证明题

设  $x = [x_1, x_2]^T$  为二维空间中的特征向量，二分类问题的线性判别函数为  $g(x) = w^T x + w_0$ ，其中权向量  $w = [w_1, w_2]^T$  是决策方程  $g(x) = 0$  对应的超平面的法向量，其长度为  $\|w\|$ 。


(1) 证明：从  $x$  到超平面  $g(x) = 0$  的距离为：

$$r = \frac{|g(x)|}{\|w\|}$$

(2) 证明： $x$  在超平面上的投影为：

$$x_p = x - \frac{|g(x)|}{\|w\|^2} w$$

答案：



(1) 设  $x$  到超平面的距离向量为  $x_d$ ， $x$  在超平面上的投影向量为  $x_p$ ，则有

$$x = x_p + x_d$$

若  $x_d$  与  $w$  同向，则有

$$g(x) = w^T x + w_0 = w^T \left( x_p + r \frac{w}{\|w\|} \right) + w_0 = g(x_p) + r \frac{w^T w}{\|w\|} = r \|w\|$$

若  $x_d$  与  $w$  反向，则有

$$g(x) = w^T x + w_0 = w^T \left( x_p - r \frac{w}{\|w\|} \right) + w_0 = g(x_p) - r \frac{w^T w}{\|w\|} = -r \|w\|$$

(2) 设  $x$  到超平面的距离向量为  $x_d$ ， $x$  在超平面上的投影向量为  $x_p$ ，则有

$$x = x_d + x_p$$

若  $x_d$  与  $w$  同向，则有

$$x_p = x - r \frac{w}{\|w\|} = x - \frac{g(x)}{\|w\|} \frac{w}{\|w\|} = x - \frac{|g(x)|}{\|w\|^2} w$$

若  $x_d$  与  $w$  反向，则有

$$x_p = x + r \frac{w}{\|w\|} = x + \frac{-g(x)}{\|w\|} \frac{w}{\|w\|} = x - \frac{|g(x)|}{\|w\|^2} w$$

# 第三章习题

## □ 一、填空题（3分）

1. 构建决策树时，选择最优划分属性的准则有\_\_\_\_\_。

答案：信息增益、增益率、基尼指数

2. 在决策树中，信息熵越大，证明样本集合的纯度越\_\_\_\_\_（高/低）。

答案：低  $H(X) = -\sum_{i=1}^n p_i \log_2 p_i$

3. 构建决策树的信息增益准则对取值数目更\_\_\_\_\_的属性有利。

答案：多


■ 代表在一个条件下信息不确定性减少的程度

■ 定义：属性  $a$  对样本集  $D$  的信息增益  $\text{Gain}(D, a)$  定义为样本集  $D$  的经验熵  $H(D)$  与属性  $a$  给定条件下样本集  $D$  的经验条件熵  $H(D|a)$  之差，即：

$$\begin{aligned}\text{Gain}(D, a) &= H(D) - H(D|a) \\ &= H(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} H(D^v)\end{aligned}$$

■ 上式中， $\frac{|D^v|}{|D|}$  表示属性  $a$  的边缘分布； $H(D^v)$  表示属性  $a$  取值  $a^v$  时，样本集  $D$  的条件概率分布的熵

补充：  $\nabla^{|y|} |D_k|, |D_k|$



# 第三章习题

## 二、选择题（3分）

1. （单选题）以下关于决策树的说法错误的是（ B ）

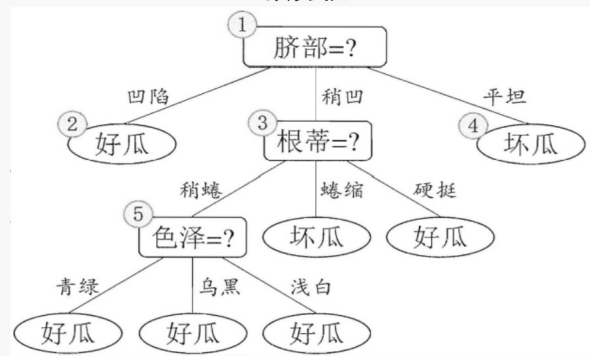
- A. 决策树容易过拟合，可以使用预剪枝或后剪枝进行处理
- B. 相比于预剪枝，后剪枝更容易得到更简单的决策树
- C. 后剪枝需要判断根结点的剪枝与否
- D. 决策树既可用于分类问题，也可用于回归问题

2. （多选题）关于决策树方法，以下说法正确的是（ AD ）

- A. 多变量决策树能得到与坐标轴呈一定夹角的分类面
- B. 增益率准则对取值数目多的属性有所偏好
- C. 基尼指数衡量了数据在类别上的不确定性的减小程度
- D. 预剪枝和后剪枝策略都可以用于预防过拟合



预剪枝



后剪枝

$$\text{GainRatio}(D, a) = \text{Gain}(D, a) / \text{IV}(a)$$

$$\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log \frac{|D^v|}{|D|}$$

$$\text{Gini}(D) = 1 - \sum_{k=1}^{|y|} p_k^2$$

$$\text{GiniIndex}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

## 第三章习题

□ 下表是由15个样本组成的贷款申请数据集，数据包括贷款申请人的年龄、收入情况、是否有车、信用情况四项属性，最后一列为是否同意贷款，作为我们的预测结果：

1. 假如我们按照小于30岁、30到 60岁、大于60岁将申请人的年龄分为三组，并将{5, 6, 14, 15}号样本作为验证集，其余样本作为训练集。请利用增益率和后剪枝策略建立决策树，写出决策树的建立过程并画出最终的决策树结构。
2. 将1中的增益率准则替换为基尼指数准则，后剪枝策略替换为预剪枝策略，请重新建立决策树，写出决策树的建立过程并画出最终的决策树结构。

序号	年龄	是否有车	收入情况	信用情况	是否同意贷款
1	19	否	一般	一般	否
2	22	否	一般	好	否
3	75	否	一般	一般	否
4	21	否	一般	一般	否
5	36	否	一般	一般	否
6	40	否	一般	好	否
7	69	是	一般	好	是
8	45	是	良好	好	是
9	52	是	一般	非常好	是
10	66	是	一般	非常好	是
11	25	否	良好	好	是
12	42	是	一般	非常好	是
13	59	否	良好	好	是
14	61	否	良好	非常好	是
15	29	是	良好	一般	是

# 第三章习题

解答：

1. 以划分根节点为例。首先计算各属性的增益率，如下：

$$Ent(D) = -\left(\frac{4}{11} \log \frac{4}{11} + \frac{7}{11} \log \frac{7}{11}\right) = 0.946$$

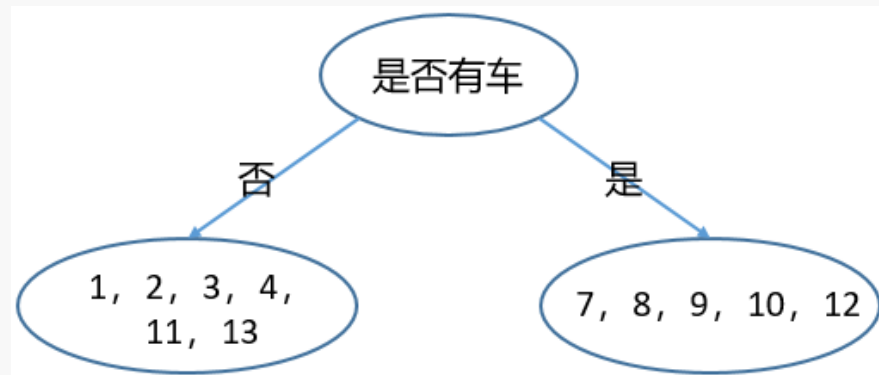
$$Gain(\text{年龄}) = Ent(D) - \left(-\frac{4}{11} \left(\frac{3}{4} \log \frac{3}{4} + \frac{1}{4} \log \frac{1}{4}\right) - \frac{4}{11} * 0 - \frac{3}{11} \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3}\right)\right) = 0.400$$

$$GainRatio(\text{年龄}) = \frac{Gain(\text{年龄})}{-\frac{4}{11} \log \frac{4}{11} - \frac{4}{11} \log \frac{4}{11} - \frac{3}{11} \log \frac{3}{11}} = 0.254$$

$$GainRatio(\text{是否有车}) = \frac{Gain(\text{是否有车})}{-\frac{6}{11} \log \frac{6}{11} - \frac{5}{11} \log \frac{5}{11}} = 0.447$$

$$GainRatio(\text{收入情况}) = \frac{Gain(\text{收入情况})}{-\frac{8}{11} \log \frac{8}{11} - \frac{3}{11} \log \frac{3}{11}} = 0.258$$

$$GainRatio(\text{信用情况}) = \frac{Gain(\text{信用情况})}{-\frac{3}{11} \log \frac{3}{11} - \frac{5}{11} \log \frac{5}{11} - \frac{3}{11} \log \frac{3}{11}} = 0.401$$



由以上对比可知，应该用“是否有车”作为划分属性，得到如下部分树：



## 第三章习题

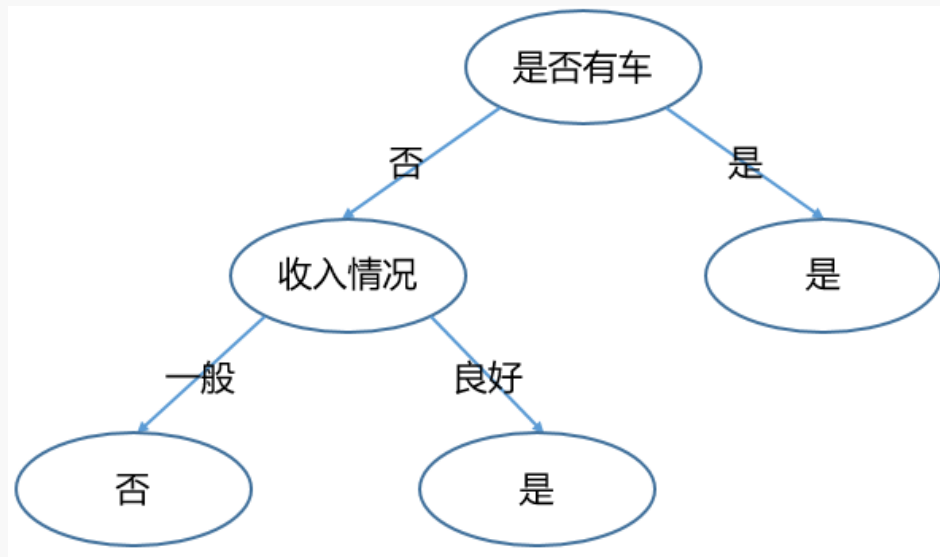
解答：

1. 建树完成后得到的决策树如右图所示。

考虑对“收入情况”节点进行后剪枝，首先计算剪枝前验证集准确率为100%，不需要再计算剪枝后准确率，因为正确率已经达到最大值，故剪枝结束，最终的决策树如下图所示。

后剪枝注意事项：

- 1) 列出所有非叶子节点后，从底向上考虑
- 2) 如果剪枝后准确率 **小于等于** 剪枝前，则放弃剪枝。



# 第三章习题

解答：

2. 首先计算各属性的基尼指数，如下：

$$GiniIndex(\text{年龄}) = \frac{4}{11} \left( 1 - \frac{3}{4} * \frac{3}{4} - \frac{1}{4} * \frac{1}{4} \right) + \frac{4}{11} * 0 + \frac{3}{11} \left( 1 - \frac{1}{3} * \frac{1}{3} - \frac{2}{3} * \frac{2}{3} \right) = 0.258$$

$$GiniIndex(\text{是否有车}) = \frac{6}{11} \left( 1 - \frac{2}{6} * \frac{2}{6} - \frac{4}{6} * \frac{4}{6} \right) + \frac{5}{11} * 0 = 0.242$$

$$GiniIndex(\text{收入情况}) = \frac{8}{11} \left( 1 - \frac{4}{8} * \frac{4}{8} - \frac{4}{8} * \frac{4}{8} \right) + \frac{3}{11} * 0 = 0.364$$

$$GiniIndex(\text{信用情况}) = \frac{3}{11} * 0 + \frac{5}{11} * \left( 1 - \frac{1}{5} * \frac{1}{5} - \frac{4}{5} * \frac{4}{5} \right) + \frac{3}{11} * 0 = 0.145$$

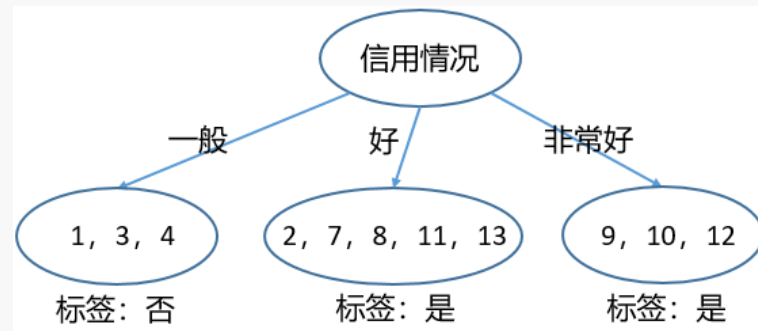
由以上对比可知，应选用“信用情况”作为划分属性，可得到如右图决策树。

考虑预剪枝，划分前：由于训练集根节点中正例较多，因此将根结点标签定为“是”，可计算出验证集准确率为50%；划分后，准确率为50%。划分前后验证集准确率没有变化，说明这次划分没有提升模型的泛化能力，所以停止划分。

预剪枝注意事项：

1) 划分一次剪一次

2) 如果划分后验证集准确率小于等于划分前，则放弃划分



# 第四章习题

## □ 选择题

### ■ 神经网络必须具备的性质：非线性，可以通过反向传播训练


#### 一、选择题

1. (多选题) 下列针对激活函数 (如 ReLU, Sigmoid, Tanh 等) 的说法, 正确的是 (BD)


- A. 它们必须是可导的
- B. 它们可以在某些点不可导, 但这些不可导的点必须很少
- C. 它们可以是任意的连续函数
- D. 它们必须是非线性的

2. (单选题) 下列哪类谓词逻辑问题不能用简单感知器解决? (D)


- A. 与
- B. 或
- C. 非
- D. 异或




“与” 运算



“或” 运算



“非” 运算



“异或” 运算

# 第四章习题

## □ 选择题

### ■ 神经网络必须具备的性质：非线性，可以通过反向传播训练


#### 一、选择题

1. (多选题) 下列针对激活函数 (如 ReLU, Sigmoid, Tanh 等) 的说法, 正确的是 (BD)


- A. 它们必须是可导的
- B. 它们可以在某些点不可导, 但这些不可导的点必须很少
- C. 它们可以是任意的连续函数
- D. 它们必须是非线性的

2. (单选题) 下列哪类谓词逻辑问题不能用简单感知器解决? (D)


- A. 与
- B. 或
- C. 非
- D. 异或




“与” 运算



“或” 运算



“非” 运算




“异或” 运算

## □ 简答题

### 二、简答题

请分析采用反向传播算法训练神经网络时，学习率过大或过小时会产生什么负面影响。

- 学习率过大：训练振动，容易跳过极小值点
- 学习率过小：容易陷入局部最优；训练较慢



## □ 证明题

### 三、证明题

试证明：多层感知机中节点的激活函数如果采用线性函数，网络无法实现非线性映射。

- 感知机的运算本质就是矩阵的线性运算，如果激活函数也采用线性，最终运算结果也是输入的线性组合

## □ 计算题

### 四、计算题

给定前向传播神经网络如下图所示,  $\{\mathbf{x}^{(i)}, y^{(i)}\}, i = 1, \dots, N$  为样本,  $\mathbf{x}^{(i)} \in \mathbb{R}^m$  为输入。


$$v_j^{(i)} = \sigma\left(\sum_{k=1}^3 w_{k,j} x_k^{(i)}\right), \quad \sigma(z) = \frac{1}{1 + \exp(-z)}$$

输出  $\hat{y}^{(i)} = \sigma(\boldsymbol{\theta}^T \mathbf{v}^{(i)})$ , 损失函数为

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N (y^{(i)} \log \hat{y}^{(i)} + (1 - y^{(i)}) \log(1 - \hat{y}^{(i)}))$$

1. 求  $\frac{\partial \mathcal{L}}{\partial \theta_2}$ 。

2. 设学习率为  $\eta$ , 求用随机梯度下降法更新  $w_{1,2}$  的表达式。



解答:

(1)

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \hat{y}^{(i)}} &= -\frac{1}{N} \left( \frac{y^{(i)}}{\hat{y}^{(i)}} + \frac{1 - y^{(i)}}{\hat{y}^{(i)} - 1} \right) = -\frac{1}{N} \frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(\hat{y}^{(i)} - 1)} \\ \frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} &= \hat{y}^{(i)}(1 - \hat{y}^{(i)}) \\ \frac{\partial z^{(i)}}{\partial \theta_2} &= v_2^{(i)} \end{aligned}$$

则

$$\frac{\partial \mathcal{L}}{\partial \theta_2} = \sum_{i=1}^N \frac{\partial \mathcal{L}}{\partial \hat{y}^{(i)}} \frac{\partial \hat{y}^{(i)}}{\partial z^{(i)}} \frac{\partial z^{(i)}}{\partial \theta_2} = \frac{1}{N} \sum_{i=1}^N (\hat{y}^{(i)} - y^{(i)}) v_2^{(i)}$$

(2)

$$\begin{aligned} \frac{\partial \hat{y}^{(i)}}{\partial v_2^{(i)}} &= \hat{y}^{(i)}(1 - \hat{y}^{(i)}) \theta_2, \quad \frac{\partial v_2^{(i)}}{\partial w_{1,2}} = v_2^{(i)}(1 - v_2^{(i)}) x_1^i \\ \frac{\partial \mathcal{L}}{\partial w_{1,2}} &= \sum_{i=1}^N \frac{\partial \mathcal{L}}{\partial \hat{y}^{(i)}} \frac{\partial \hat{y}^{(i)}}{\partial v_2^{(i)}} \frac{\partial v_2^{(i)}}{\partial w_{1,2}} = -\frac{\hat{y}^{(i)} - y^{(i)}}{\hat{y}^{(i)}(\hat{y}^{(i)} - 1)} \hat{y}^{(i)}(1 - \hat{y}^{(i)}) \theta_2 v_2^{(i)}(1 - v_2^{(i)}) x_1^i \\ &= (\hat{y}^{(i)} - y^{(i)}) v_2^{(i)}(1 - v_2^{(i)}) \theta_2 x_1^i \end{aligned}$$

则,  $w_{1,2} \leftarrow w_{1,2} - \eta (\hat{y}^{(i)} - y^{(i)}) v_2^{(i)}(1 - v_2^{(i)}) \theta_2 x_1^i$

## □ 一、选择题（3分）

1. （单选题）SVM的有效性取决于（ D ）

- A. 核函数选择      B. 核函数参数      C. 软边距参数      D. 以上所有

2. （多选题）下列说法中错误的是（ BC ）

A. 支持向量机的分类超平面只与支持向量有关

B. SVM是一种常见的线性分类器，它不能对数据做非线性分类

C. 软间隔支持向量机  $\min \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$  中的C越大，模型的复杂度越低

D. 核函数能将数据特征提升到更高维空间

$$\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i$$

$$\hat{y} = \text{sgn} \left( \sum_{i=1}^n \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right)$$

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{s. t.} \quad & y_i (\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, n \\ & \xi_i \geq 0, \quad i = 1, \dots, n \end{aligned}$$



## □ 二、计算题

1. 给定正例 $x_1 = (1,1)$ ,  $x_2 = (-1,3)$ , 负例 $x_3 = (2,3)$ ,  $x_4 = (2,4)$ , 计算支持向量、分类决策函数和分类超平面方程。 (3分)

### □ 解法一：用对偶形式计算

■ 首先写出对偶形式：

$$\begin{aligned} \max \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \\ \text{s.t.} \quad & \alpha_1 + \alpha_2 = \alpha_3 + \alpha_4 \\ & \alpha_i \geq 0 \end{aligned}$$

■ 将 $\alpha_4 = \alpha_1 + \alpha_2 - \alpha_3$ 代入上式得到目标函数

$$S(\alpha_1, \alpha_2, \alpha_3) = 2\alpha_1 + 2\alpha_2 - \frac{1}{2}(10\alpha_1^2 + 10\alpha_2^2 + \alpha_3^2 + 12\alpha_1\alpha_2 - 6\alpha_1\alpha_3 - 2\alpha_2\alpha_3)$$

## □ 二、计算题

### □ 解法一：用对偶形式计算

- 将目标函数对 $\alpha_1, \alpha_2, \alpha_3$ 分别求偏导，令偏导数为0：

$$\frac{\partial S}{\partial \alpha_1} = 2 - 10\alpha_1 - 6\alpha_2 + 3\alpha_3 = 0$$

$$\frac{\partial S}{\partial \alpha_2} = 2 - 10\alpha_2 - 6\alpha_1 + \alpha_3 = 0$$

$$\frac{\partial S}{\partial \alpha_3} = -\alpha_3 + 3\alpha_1 + \alpha_2 = 0$$

- 方程组无解，说明最大值在边界处， $\alpha_1, \alpha_2, \alpha_3, \alpha_4$ 中存在0
- 当 $\alpha_1 = 0$ 时，解得 $\alpha_1 = 0, \alpha_2 = \alpha_3 = \frac{2}{9}, \alpha_4 = 0$ ，带入可得 $S = -\frac{4}{9}$
- 当 $\alpha_2 = 0$ 时，解得 $\alpha_1 = \alpha_3 = \frac{2}{5}, \alpha_2 = \alpha_4 = 0$ ，代入得 $S = \frac{2}{5}$
- 当 $\alpha_3 = 0$ 时，解得 $\alpha_1 = \alpha_2 = \frac{1}{8}, \alpha_4 = \frac{1}{4}$ ，带入可得 $S = \frac{1}{4}$
- 当 $\alpha_4 = 0$ 时，解得 $\alpha_1 = \frac{1}{3}, \alpha_2 = \frac{1}{9}, \alpha_3 = \frac{4}{9}$ ，带入可得 $S = \frac{4}{9}$

## □ 二、计算题


### □ 解法二：直接画图

- 画出各个样本的坐标
- 直接确定支持向量
- 非支持向量的 $\alpha$ 为0
- 计算得到超平面方程：

$$-\frac{2}{3}x_1 - \frac{2}{3}x_2 + \frac{7}{3} = 0$$

- 分类决策函数：

$$\hat{y} = \text{sgn}(w^*x + b^*) = \text{sgn}\left(-\frac{2}{3}x_1 - \frac{2}{3}x_2 + \frac{7}{3}\right)$$



## 二、计算题

2. 考虑SVM（支持向量机）和来自两个类别的训练数据如下：

(1) 通过拉格朗日法构建出SVM求解最优超平面的对偶优化问题。（1分）


(2) 求解支持向量。（2分）

(3) 画出表格中6个数据点，支持向量，最优超平面以及决策边界。（1分）

直接画图求解

支持向量机的  
对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j) \\ \text{s.t.} \quad & \alpha_i \geq 0, \quad i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$



## □ 一、选择题（3分）

1. （单选题）若将经验风险中的损失函数由  $\lambda(\hat{\theta}, \theta) = (\theta - \hat{\theta})^2$  替换为  $\lambda(\hat{\theta}, \theta) = |\theta - \hat{\theta}|$ ，则  $\theta$  的贝叶斯估计量为（ B ）

A. 后验均值      B. 后验中值      C. 后验最大值      D. 以上都不对

2. （单选题）关于参数估计，下面哪项说法不正确（ C ）

A. 当训练样本数无穷多的时候，最大似然估计和贝叶斯估计的结果是一样的

B. 最大似然估计比较简单直观

C. 贝叶斯估计就是后验分布的最大值点 后验均值

D. 若先验概率的信息是可靠的，那么可以认为贝叶斯估计比最大似然估计的结果更准确

$$\min_{\hat{\theta}} \int_{-\infty}^{\infty} |\theta - \hat{\theta}| p(\theta|D) d\theta = \int_{-\infty}^{\hat{\theta}} (\hat{\theta} - \theta) p(\theta|D) d\theta + \int_{\hat{\theta}}^{\infty} (\theta - \hat{\theta}) p(\theta|D) d\theta \quad \int_{-\infty}^{\hat{\theta}} p(\theta|D) d\theta - \int_{\hat{\theta}}^{\infty} p(\theta|D) d\theta = 0$$

## □ 二、计算题

1. (贝叶斯决策) 在二分类任务中, 假定类型 $w_1$ 和 $w_2$ 分别为两个目标类别, 已知先验概率分别为 $P(w_1) = 0.2$ 和 $P(w_2) = 0.8$ , 两类概率密度函数分别表示如下:

$$P(x|\omega_1) = \begin{cases} x, & 0 \leq x < 1 \\ 2 - x, & 1 \leq x \leq 2 \\ 0, & \text{else} \end{cases} \quad P(x|\omega_2) = \begin{cases} x - 1, & 1 \leq x < 2 \\ 3 - x, & 2 \leq x \leq 3 \\ 0, & \text{else} \end{cases}$$

- (1) 求贝叶斯最小错误率准则下的判决域, 并判断样本 $x=1.5$ 属于哪一类;  
(2) 使用 (1) 中的判别准则和判别域, 求总错误概率 $P(e)$

**解答:**

- (1) 比较 $P(\omega_1)P(x|\omega_1)$ 与 $P(\omega_2)P(x|\omega_2)$ 可得到决策分类面 $x=1.2$

判决域: 当 $x < 1.2$ 时, 分类为 $\omega_1$ 类, 当 $x > 1.2$ 时, 分类为 $\omega_2$ 类。所以 $x=1.5$ 时, 会被分为 $\omega_2$ 类

$$(2) P(e) = \int_{-\infty}^{1.2} P(\omega_2)P(x|\omega_2)dx + \int_{1.2}^{+\infty} P(\omega_1)P(x|\omega_1)dx = 0.08$$

## □ 二、计算题

2. (最大似然估计) 假设 $(X_1, \dots, X_n)$ 是来自概率密度函数如下的一组随机样本, 求 $\theta$ 的最大似然估计。

$$f(x|\theta) = \theta x^{-2} \quad 0 < \theta \leq x < \infty$$

解答:

$$L(\mathbf{x}; \theta) = \prod_{i=1}^n f(x_i|\theta) = \theta^n \left( \prod_{i=1}^n x_i \right)^{-2}$$

$$l(\mathbf{x}; \theta) = \log L(\mathbf{x}; \theta) = n \log \theta - 2 \sum_{i=1}^n \log x_i$$

$$\frac{\partial l(\mathbf{x}; \theta)}{\partial \theta} = \frac{n}{\theta} > 0$$

则 $l(\mathbf{x}; \theta)$ 单调递增。根据 $0 < \theta \leq x < \infty$ , 则有

$$\hat{\theta} = \min\{X_1, \dots, X_n\}$$