

运筹学

9. 非线性规划基础

李 力
清华大学

Email: li-li@tsinghua.edu.cn

2023.4.

非线性规划部分主要内容

基础知识（凸优化问题，
凸函数，可行下降方法）

一维搜索（直线搜索）

无约束优化（下降方向）

约束优化（KT条件）

算法（简约梯度，罚函数，障碍函数）

基础知识

非线性规划的一般形式

$$\begin{aligned} \min \quad & f(X) \\ \text{s.t.} \quad & h_i(X) = 0, \quad i = 1, 2, \dots, m \\ & g_j(X) \leq 0, \quad j = 1, 2, \dots, l \end{aligned}$$

其中 $X = (x_1, x_2, \dots, x_n)^T \in R^n$

定义可行集

$$\Omega = \left\{ X \in R^n \mid h_i(X) = 0, \quad 1 \leq i \leq m, \quad g_j(X) \leq 0, \quad 1 \leq j \leq l \right\}$$

上述一般形式可简写成

$$\min_{X \in \Omega} f(X)$$

\hat{X} 的 ε 邻域: $B(\hat{X}, \varepsilon) = \{X \in R^n \mid \|X - \hat{X}\| < \varepsilon\}$

局部最优解 \hat{X} : $\hat{X} \in \Omega$, 且存在 $\varepsilon > 0$ 满足



$$f(\hat{X}) \leq f(X), \quad \forall X \in B(\hat{X}, \varepsilon) \cap \Omega$$

全局最优解 \hat{X} : $\hat{X} \in \Omega, f(\hat{X}) \leq f(X), \quad \forall X \in \Omega$


严格局部最优条件 $f(\hat{X}) < f(X), \quad \forall X \in B(\hat{X}, \varepsilon) \cap \Omega - \{\hat{X}\}$

严格全局最优条件 $f(\hat{X}) < f(X), \quad \forall X \in \Omega - \{\hat{X}\}$

函数的局部最小/大值 (Minimal/Maximal) 和全局最小/大值 (Minimum/Maximum)



$$\min_{X \in \Omega} -x_1^2 - x_2^2$$



○ 邻域 ● 局部最优解 ● 全局最优解

如何判断找到了局部或全局最优解？

什么样的非线性目标函数可以方便的判定
是否找到了局部或全局最优解？

为此，人们开始研究凸优化问题

为什么研究凸优化？

1. 现实生活中，很多问题都属于凸优化问题。例如线性规划就是凸优化问题的特例。
2. 凸优化问题性质好，可以进行深入的理论分析。很大一部分凸优化问题是多项式时间可解问题，我们已经建立了十分有效的求解算法，可以快速求得全局最优解。
3. 凸优化是研究连续变量优化的起点和基础。目前很多非凸优化问题中非凸性的刻画都脱胎于凸优化，相关问题的求解也和凸优化联系在一起，常常有赖于找到这些非凸优化问题中“凸”的结构。

非线性优化问题的定义和最优解要涉及以下知识：

一元函数的一阶/二阶导数、多元函数的梯度和Hesse阵

凸函数的定义及其性质

- 多元凸函数的基本定义和性质
- 凸函数的局部最优解和全局最优解
- 多元凸函数的一阶充要条件
- 多元凸函数的二阶充分条件和必要条件
- 多元凸函数和一元凸函数的关系
- 典型的凸函数

标量函数求偏导数（梯度）

$$\nabla f(X) = \frac{\partial f(X)}{\partial X} = \begin{pmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \\ \vdots \\ \frac{\partial f(X)}{\partial x_n} \end{pmatrix}$$

$$\nabla^T f(X) = \frac{\partial f(X)}{\partial X^T} = \left(\frac{\partial f(X)}{\partial x_1}, \frac{\partial f(X)}{\partial x_2}, \dots, \frac{\partial f(X)}{\partial x_n} \right)$$

典型函数 $f(x_1, x_2) = x_1^2 + 2 x_1 x_2 + x_2^2$

向量函数求偏导数

$$F(X) = (f_1(X), f_2(X), \dots, f_m(X))^T$$

$$\begin{aligned}\frac{\partial F^T(X)}{\partial X} &= \left(\frac{\partial f_1(X)}{\partial X}, \frac{\partial f_2(X)}{\partial X}, \dots, \frac{\partial f_m(X)}{\partial X} \right)_{n \times m} \\ &= (\nabla f_1(X), \nabla f_2(X), \dots, \nabla f_m(X))_{n \times m}\end{aligned}$$

$$\frac{\partial F(X)}{\partial X^T} = \begin{pmatrix} \frac{\partial f_1(X)}{\partial X^T} \\ \frac{\partial f_2(X)}{\partial X^T} \\ \vdots \\ \frac{\partial f_m(X)}{\partial X^T} \end{pmatrix}_{m \times n} = \begin{pmatrix} \nabla^T f_1(X) \\ \nabla^T f_2(X) \\ \vdots \\ \nabla^T f_m(X) \end{pmatrix}_{m \times n}$$

海赛（Hesse, Hessian）矩阵

$$\nabla^2 f(X) = \frac{\partial \nabla f(X)}{\partial X^T} = \begin{bmatrix} \frac{\partial^2 f(X)}{\partial x_1 x_1} & \frac{\partial^2 f(X)}{\partial x_1 x_2} & \dots & \frac{\partial^2 f(X)}{\partial x_1 x_n} \\ \frac{\partial^2 f(X)}{\partial x_2 x_1} & \frac{\partial^2 f(X)}{\partial x_2 x_2} & \dots & \frac{\partial^2 f(X)}{\partial x_2 x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(X)}{\partial x_n x_1} & \frac{\partial^2 f(X)}{\partial x_n x_2} & \dots & \frac{\partial^2 f(X)}{\partial x_n x_n} \end{bmatrix}$$

黑塞矩阵（Hessian Matrix），又译作海森矩阵、海瑟矩阵、海塞矩阵等，是一个多元函数的二阶偏导数构成的方阵，描述了函数的局部曲率。黑塞矩阵最早于19世纪由德国数学家Ludwig Otto Hesse提出。

对向量函数的点积求偏导数

$$F(X) = (f_1(X), f_2(X), \dots, f_m(X))^T$$

$$G(X) = (g_1(X), g_2(X), \dots, g_m(X))^T$$

$$\frac{\partial (F^T(X)G(X))}{\partial X} = \frac{\partial F^T(X)}{\partial X} G(X) + \frac{\partial G^T(X)}{\partial X} F(X)$$

$$\frac{\partial (F^T(X)G(X))}{\partial X^T} = F^T(X) \frac{\partial G(X)}{\partial X^T} + G^T(X) \frac{\partial F(X)}{\partial X^T}$$

对常数矩阵和向量函数的乘积求偏导数

$$A \in R^{m \times m} \quad F(X) = (f_1(X), f_2(X), \dots, f_m(X))^T$$

$$\frac{\partial (AF(X))^T}{\partial X} = \frac{\partial (F^T(X)A^T)}{\partial X} = \frac{\partial F^T(X)}{\partial X} A^T$$

$$\frac{\partial AF(X)}{\partial X^T} = A \frac{\partial F(X)}{\partial X^T}$$

对二次函数求偏导数 ($A^T = A \in R^{m \times m}$)

$$\frac{\partial (X^T AX)}{\partial X} = \frac{\partial X^T}{\partial X} AX + \frac{\partial (AX)^T}{\partial X} X = (A + A^T)X = 2AX$$

$$\frac{\partial (X^T AX)}{\partial X^T} = X^T \frac{\partial (AX)}{\partial X^T} + (AX)^T \frac{\partial X}{\partial X^T} = X^T (A + A^T) = 2X^T A$$

一元函数在原点的二阶泰勒（Taylor）展开

$$g(t) = g(0) + c_1 t + \frac{1}{2} c_2(\xi) t^2$$

需要假设存在
连续二阶导数

其中

$$0 \leq \xi \leq t$$

$$c_1 = \left. \frac{dg(t)}{dt} \right|_{t=0}$$

我们经常通过
类比一元函数
和多元函数来
增强感性理解

$$c_2(\xi) = \left. \frac{d^2 g(t)}{dt^2} \right|_{t=\xi}$$

多元函数在给定点沿给定方向的二阶泰勒展开

$$f(\hat{X} + tD) = f(\hat{X}) + c_1 t + \frac{1}{2} c_2(\xi) t^2$$

其中 $0 \leq \xi \leq t$

需要假设存在
连续二阶导数

$$c_1 = \left. \frac{df(\hat{X} + tD)}{dt} \right|_{t=0} = \nabla^T f(\hat{X}) D$$

$$c_2(\xi) = \left. \frac{d^2 f(\hat{X} + tD)}{dt^2} \right|_{t=\xi} = D^T \nabla^2 f(\hat{X} + \xi D) D$$

$$\Rightarrow f(\hat{X} + tD) = f(\hat{X}) + \nabla^T f(\hat{X}) D t + \frac{1}{2} D^T \nabla^2 f(\hat{X} + \xi D) D t^2$$

(凸集上的) 凸函数和凹函数



设 $f(X)$ 是定义在集合 $\Omega \subset R^n$ 上的函数, 如果 Ω 是凸集, 并且对 Ω 中任意两点 X_1, X_2 以及闭区间 $[0, 1]$ 中任意一点 λ 都满足

$$f(\lambda X_1 + (1-\lambda)X_2) \leq \lambda f(X_1) + (1-\lambda)f(X_2)$$

则称 $f(X)$ 是 (凸集 Ω 上的) 凸函数, 如果 $-f(X)$ 是 (凸集 Ω 上的) 凸函数, 则称 $f(X)$ 是 (凸集 Ω 上的) 凹函数, 此时在上面的条件下应满足

$$f(\lambda X_1 + (1-\lambda)X_2) \geq \lambda f(X_1) + (1-\lambda)f(X_2)$$

一元凸（凹）函数的图象



多元凸函数和一元凸函数的关系

对定义在凸集 $\Omega \subset R^n$ 上的多元函数 $f(\cdot)$ ，任取 $X \in \Omega$ 和 $D \in R^n$ 定义一元函数 $\varphi(\cdot | X, D)$ 如下

$$\varphi(t | X, D) = f(X + tD), \quad \forall X + tD \in \Omega$$

则存在以下关系

当且仅当

$f(\cdot)$ 是凸函数 $\Leftrightarrow \varphi(\cdot | X, D), \forall X \in \Omega, D \in R^n$ 是凸函数


证明：正向利用

$$\varphi((1-\lambda)t_1 + \lambda t_2 | X, D) = f((1-\lambda)(X + t_1 D) + \lambda(X + t_2 D))$$

反向利用 $f((1-t)X_1 + tX_2) = \varphi((1-t) \times 0 + t \times 1 | X_1, X_2 - X_1)$

一元可导凸函数的充要条件

$$f'(X_1)(X_2 - X_1) \leq f(X_2) - f(X_1)$$



充分性: $X(t) = (1-t)X_1 + tX_2$

$$f(X_1) - f(X(t)) \geq f'(X(t))(X_1 - X(t))$$

$$f(X_2) - f(X(t)) \geq f'(X(t))(X_2 - X(t))$$

$$\Rightarrow (1-t)(f(X_1) - f(X(t))) + t(f(X_2) - f(X(t))) \geq 0$$

$$\Leftrightarrow (1-t)f(X_1) + tf(X_2) \geq f((1-t)X_1 + tX_2)$$

必要性: $f((1-t)X_1 + tX_2) \leq (1-t)f(X_1) + tf(X_2)$

$$\Leftrightarrow \frac{f(X_1 + t(X_2 - X_1)) - f(X_1)}{t} \leq f(X_2) - f(X_1)$$

多元可导凸函数的一阶充要条件

$$\nabla^T f(X_1)(X_2 - X_1) \leq f(X_2) - f(X_1), \quad \forall X_1, X_2 \in \Omega$$

充分性: $g(t_i) = f(X + t_i V) = f(X_i), \quad i = 1, 2$

$$\Rightarrow g'(t_1) = \nabla f(X + t_1 V)^T V$$

$$\begin{aligned} \Rightarrow g(t_2) - g(t_1) &= f(X_2) - f(X_1) \geq \nabla f(X_1)^T (X_2 - X_1) \\ &= \nabla f(X + t_1 V)^T V (t_2 - t_1) = g'(t_1)(t_2 - t_1) \end{aligned}$$

必要性: $g'(t) = \nabla f(X_1 + t(X_2 - X_1))^T (X_2 - X_1)$

$$g'(0) = \nabla f(X_1)^T (X_2 - X_1)$$

$$g'(0)(1-0) \leq g(1) - g(0), \quad \forall X_1, X_2 \in \Omega$$

一元二阶可导凸函数的二阶充分条件

$$f''(X) \geq 0, \forall X \in \Omega$$

证明

$$\text{已知条件} \Rightarrow f'(X_2) \geq f'(X_1), \forall X_2 \geq X_1$$

情况1 $X_2 \geq X_1$ ($\xi \geq X_1$)

$$f(X_2) - f(X_1) = f'(\xi)(X_2 - X_1) \geq f'(X_1)(X_2 - X_1)$$

情况2 $X_2 \leq X_1$ ($\xi \leq X_1$)

$$f(X_2) - f(X_1) = f'(\xi)(X_2 - X_1) \geq f'(X_1)(X_2 - X_1)$$

由一阶充要条件知结论成立

(只需要二阶导数存在)

一元二阶可导凸函数的二阶必要条件

$$f''(X) \geq 0, \forall X \in \Omega \quad \text{其中 } \Omega \text{ 不是单点集}$$

证明 必存在 $|\Delta X| \in B(0, \varepsilon) \Rightarrow X + \Delta X \in \Omega$

$$\Rightarrow f'(X)(\Delta X) \leq f(X + \Delta X) - f(X)$$

$$f'(X + \Delta X)(-\Delta X) \leq f(X + \Delta X + (-\Delta X)) - f(X + \Delta X)$$

$$\Rightarrow (f'(X + \Delta X) - f'(X))\Delta X \geq 0$$

$$\Rightarrow \frac{(f'(X + \Delta X) - f'(X))(\Delta X)^2}{\Delta X} \geq 0 \Rightarrow f''(X) \geq 0$$

多元二阶可导凸函数的二阶充分条件

$$\nabla^2 f(X) \geq 0, \quad \forall X \in \Omega$$

证明途径

$$g(t) = f(X_1 + t(X_2 - X_1))$$

$$g'(t) = \nabla f(X_1 + t(X_2 - X_1))^T (X_2 - X_1)$$

$$g''(t) = (X_2 - X_1)^T \nabla^2 f(X_1 + t(X_2 - X_1)) (X_2 - X_1)$$

$$\nabla^2 f(X) \geq 0, \quad \forall X \in \Omega \quad \Rightarrow \quad g''(t) \geq 0$$

$$\Rightarrow \quad g(t) \text{ 是一元凸函数}$$

多元二阶可导凸函数的二阶必要条件

$$\nabla^2 f(X) \geq 0, \quad \forall X \in \Omega \quad \text{其中 } \Omega \text{ 是开集}$$

证明途径

对任意的 $X \in \Omega$ 和模充分小的 $\Delta X \in R^n$

$g(t) = f(X + t\Delta X)$ 是含零开区间上的凸函数

$$g'(t) = \nabla f(X + t\Delta X)^T \Delta X$$

$$g''(t) = \Delta X^T \nabla^2 f(X + t\Delta X) \Delta X$$

$$\Delta X^T \nabla^2 f(X) \Delta X = g''(0) \geq 0 \quad \Rightarrow \quad \nabla^2 f(X) \geq 0$$

凸性对优化问题的基本作用 （回答Page 8的问题）

如果 Ω 是凸集， $f(X)$ 是其上的连续凸函数，称

$$\min_{X \in \Omega} f(X)$$

是凸规划问题

如果 $X^* \in \Omega$ 是凸规划问题的任意一个局部最优

解，那么它也是该问题的全局最优解

证明：如果存在 $\hat{X} \in \Omega$ 满足 $f(\hat{X}) < f(X^*)$

$$\Rightarrow \lambda f(\hat{X}) < \lambda f(X^*), \quad \forall \lambda > 0$$

又因为

$$f(\lambda \hat{X} + (1-\lambda)X^*) \leq \lambda f(\hat{X}) + (1-\lambda)f(X^*), \quad \forall 0 \leq \lambda \leq 1$$

$$\Rightarrow f(\lambda \hat{X} + (1-\lambda)X^*) < f(X^*), \quad \forall 0 < \lambda \leq 1$$

因为对充分小的 $\lambda > 0$ ， $\lambda \hat{X} + (1-\lambda)X^*$ 能够充分

接近 X^* ，说明 X^* 不是局部最优解，矛盾

典型的凸函数包括：


- 指数函数 e^{ax} ，负对数函数
- 仿射函数（同时是凸函数和凹函数）
- 正定或者半正定二次函数 $x^T Ax + b^T x + c$
- 范数（无法利用凸性的一阶条件以及二阶条件进行证明，因为范数本身可能并不是处处可微的）
- 幂函数 x^p ，绝对值幂函数 $|x|^p$ （ $p \geq 1$ 为凸函数， $p \in (0,1)$ 为凹函数）

典型的凹函数包括：

- 对数函数 $\log(x)$


非凸函数

LOCAL AND GLOBAL MINIMA



Unconstrained local and global minima in one dimension.




非凸函数



$$x_1^2 - x_2^2$$

非凸函数

- There may exist points that satisfy the 1st and 2nd order conditions but are not local minima



First and second order necessary optimality conditions for functions of one variable.