
简约梯度法

处理的问题

简约梯度法（**reduced gradient method**）处理带有线性约束的非线性规划问题。其标准形式为：

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{array} \quad (\text{LC-MP})$$

其中， $x \in \mathbb{R}^n$ ， $f : \mathbb{R}^n \mapsto \mathbb{R}$ ， $r(A_{m \times n}) = m$ ， $b \in \mathbb{R}^m$ 。

LC-MP 的可行域记为： $X_l = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}$ 。

简约梯度法的基本思想

- 将一个可行解 x^k 的前 m 个最大的正分量定义为**基变量**，其余的 $n - m$ 个变量定义为**非基变量**。（仿照 LP 的单纯形算法——但不完全相同）。
- 为此，假设（1） X_l 中的每一个可行解至少有 m 个大于零的分量；（2） A 的任意 m 列线性无关。——**非退化假设**。
- 因为可行解 x^k 满足约束 $A \begin{pmatrix} x_B^k \\ x_N^k \end{pmatrix} = b$ ， x^k 中的基变量 x_B^k 可用非基变量 x_N^k 表示。从而，目标函数 f 可写为非基变量 x_N^k 的函数。
- **基本思想**：根据这样的目标函数的负梯度方向构造可行下降方向 p^k ，沿 p^k 搜索下一个可行解 x^{k+1} 。

计算目标函数的梯度

- 按基变量的定义，可行解 $x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$ ，约束矩阵 A 也相应划分为 (B, N) 。不失一般性，假设 B 恰好由 A 的第 1 列~第 m 列组成， N 因此由第 $m + 1$ 列~第 n 列组成。
- $Ax = b \Rightarrow Bx_B + Nx_N = b \Rightarrow x_B = B^{-1}b - B^{-1}Nx_N$ 。
- 因此目标函数 $f(x) = f(x_B, x_N) = f(B^{-1}b - B^{-1}Nx_N, x_N)$ ，记为 $F(x_N)$ 。
- 下面计算 $\nabla F(x_N) = \left(\frac{\partial F}{\partial x_{m+1}}(x_N), \frac{\partial F}{\partial x_{m+2}}(x_N), \dots, \frac{\partial F}{\partial x_n}(x_N) \right)^T$ 。

计算目标函数的梯度

- 为此，将 $F(x_N)$ 重写为 $F(x_N) = f(u(x_N), v(x_N))$ ，其中 $u(x_N) = B^{-1}b - B^{-1}Nx_N$ ， $v(x_N) = x_N$ 。
- 应用复合函数求导法则，有：

$$\begin{aligned} & \frac{\partial F}{\partial x_{m+1}}(x_N) \\ &= \frac{\partial f(u, v)}{\partial u_1} \frac{\partial u_1(x_N)}{\partial x_{m+1}} + \frac{\partial f(u, v)}{\partial u_2} \frac{\partial u_2(x_N)}{\partial x_{m+1}} + \dots + \frac{\partial f(u, v)}{\partial u_m} \frac{\partial u_m(x_N)}{\partial x_{m+1}} \\ & \quad + \frac{\partial f(u, v)}{\partial v_1} \frac{\partial v_1(x_N)}{\partial x_{m+1}} + \frac{\partial f(u, v)}{\partial v_2} \frac{\partial v_2(x_N)}{\partial x_{m+1}} + \dots + \frac{\partial f(u, v)}{\partial v_{n-m}} \frac{\partial v_{n-m}(x_N)}{\partial x_{m+1}} \end{aligned}$$

$$\text{其中 } \frac{\partial v_1(x_N)}{\partial x_{m+1}} = 1, \quad \frac{\partial v_2(x_N)}{\partial x_{m+1}} = 0, \quad \dots, \quad \frac{\partial v_{n-m}(x_N)}{\partial x_{m+1}} = 0。$$

计算目标函数的梯度

- 因此，梯度向量 $\nabla F(x_N)$ 可表示为：

$$\begin{pmatrix} \frac{\partial F(x_N)}{\partial x_{m+1}} \\ \frac{\partial F(x_N)}{\partial x_{m+2}} \\ \vdots \\ \frac{\partial F(x_N)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} \frac{\partial u_1(x_N)}{\partial x_{m+1}} & \frac{\partial u_2(x_N)}{\partial x_{m+1}} & \dots & \frac{\partial u_m(x_N)}{\partial x_{m+1}} \\ \frac{\partial u_1(x_N)}{\partial x_{m+2}} & \frac{\partial u_2(x_N)}{\partial x_{m+2}} & \dots & \frac{\partial u_m(x_N)}{\partial x_{m+2}} \\ \vdots & \vdots & \dots & \vdots \\ \times & \times & \dots & \times \end{pmatrix} \begin{pmatrix} \frac{\partial f(u,v)}{\partial u_1} \\ \frac{\partial f(u,v)}{\partial u_2} \\ \vdots \\ \frac{\partial f(u,v)}{\partial u_m} \end{pmatrix} + \begin{pmatrix} \frac{\partial f(u,v)}{\partial v_1} \\ \frac{\partial f(u,v)}{\partial v_2} \\ \vdots \\ \frac{\partial f(u,v)}{\partial v_{n-m}} \end{pmatrix}$$

- 下面计算 $\frac{\partial u_1}{\partial x_{m+1}}(x_N)$, $\frac{\partial u_2}{\partial x_{m+1}}(x_N)$, 等项。

计算目标函数的梯度

● $u(x_N) = B^{-1}b - B^{-1}Nx_N :$

$$\begin{pmatrix} u_1(x_N) \\ u_2(x_N) \\ \vdots \\ u_m(x_N) \end{pmatrix} = \begin{pmatrix} \times \\ \times \\ \vdots \\ \times \end{pmatrix} - \begin{pmatrix} \times & \times & \cdots & \times \\ \times & \times & \cdots & \times \\ \vdots & & & \\ \times & \times & \cdots & \times \end{pmatrix} \begin{pmatrix} x_{m+1} \\ x_{m+2} \\ \vdots \\ x_n \end{pmatrix}$$

● $\Rightarrow \frac{\partial u_1}{\partial x_{m+1}}(x_N) = -(B^{-1}N)_{11}, \quad \frac{\partial u_2}{\partial x_{m+1}}(x_N) = -(B^{-1}N)_{21}, \quad \dots$

$$\frac{\partial u_1}{\partial x_{m+2}}(x_N) = -(B^{-1}N)_{12}, \quad \dots$$

计算目标函数的梯度

- 因此, $\nabla F(x_N) = -(B^{-1}N)^T \nabla_u f(u, v) + \nabla_v f(u, v)$
 $= -(B^{-1}N)^T \nabla_B f(x) + \nabla_N f(x),$

记为 r_N , 称为**简约梯度**,

其中 $\nabla_B f(x)$ 表示 f 对各基变量的偏导数组成的向量, $\nabla_N f(x)$ 表示 f 对各非基变量的偏导数组成的向量。

- 可行解 x^k 的简约梯度为 $r_N^k = -\left((B^k)^{-1} N^k\right)^T \nabla_B f(x^k) + \nabla_N f(x^k)$ 。

下面确定搜索方向 $p^k = \begin{pmatrix} p_B^k \\ p_N^k \end{pmatrix}$ 以构造下一个可行解

$x^{k+1} = x^k + t_k p^k$ 。先给出构造方法, 再证明其**可行**、**下降**。

构造搜索方向

- 为了保持新的解值 $f(x^{k+1})$ 下降, p_N^k 可取为 $-r_N^k$ 。但同时要保证 x^{k+1} 可行。因此, p_N^k 构造为:

$$p_i^k = \begin{cases} -r_i^k, & r_i^k \leq 0 \\ -x_i^k r_i^k, & r_i^k > 0, \end{cases} \quad i \in \text{index}(N^k)。 \quad (18a, 18b)$$

- 为了保证下一个解 x^{k+1} 可行, 必须有

$$Ax^{k+1} = Ax^k + t_k Ap^k = b, \quad \text{因此 } Ap^k = 0。$$

- $\Rightarrow B^k p_B^k + N^k p_N^k = 0, \Rightarrow p_B^k = -(B^k)^{-1} N^k p_N^k。 (19)$

搜索方向可行下降

定理 4.5.3 对于 **LC-MP** 问题 $\min\{f(x) \mid Ax = b, x \geq 0\}$ ，设目标函数 f 可微，基变量、非基变量、非退化假设、搜索方向按如上约定。则：

- (1) $p^k \neq 0 \Rightarrow p^k$ 是 f 在点 x^k 处的可行下降方向；
- (2) $p^k = 0 \Rightarrow x^k$ 是 **MP** 问题的 **K-T** 点。（（2）的逆也成立。）

- 证。（1）下一个探索点 $x^{k+1} = x^k + t_k p^k$ ，其中 $t_k > 0$ 。由 p^k 的构造，已有 $Ax^{k+1} = b$ 。下面证 $x^{k+1} \geq 0$ 。
- $x_B^{k+1} = x_B^k + t_k p_B^k$ 。由非退化假设， $x_B^k > 0$ 。因此，只要 t_k 取得适当小，即有 $x_B^{k+1} > 0$ 。

搜索方向可行

- $x_N^{k+1} = x_N^k + t_k p_N^k$ 。由于 x_N^k 是非基变量，不能保证 $x_N^k > 0$ （但必有 $x_N^k \geq 0$ ☺）。令 $i \in \text{index}(N^k)$ ，分两种情况讨论：

- 若 $x_i^k = 0$ ，则

$$x_i^{k+1} = x_i^k + t_k p_i^k = t_k p_i^k = \begin{cases} -t_k r_i^k \geq 0, & r_i^k \leq 0 \\ -t_k x_i^k r_i^k = 0, & r_i^k > 0, \end{cases}$$

因此总有 $x_i^{k+1} \geq 0$ 。

- 若 $x_i^k > 0$ ，则可类比 x_B^k 的情形处理。
- 综上，对于适当选取的 t_k ， x^{k+1} 是可行解。

搜索方向下降

- 由定理 4.4.1, 只要 $\nabla f(x^k)^T p^k < 0$, 则 p^k 即是函数 f 在 x^k 处的下降方向。

- $$\begin{aligned}\nabla f(x^k)^T p^k &= \nabla_B f(x^k)^T p_B^k + \nabla_N f(x^k)^T p_N^k \\ &= \nabla_B f(x^k)^T \left(- (B^k)^{-1} N^k p_N^k \right) + \nabla_N f(x^k)^T p_N^k \\ &= \left(- \nabla_B f(x^k)^T (B^k)^{-1} N^k + \nabla_N f(x^k)^T \right) p_N^k \\ &= (r_N^k)^T p_N^k = \sum_{i \in \text{index}(N^k)} r_i^k p_i^k.\end{aligned}$$

- 而 $r_i^k p_i^k = \begin{cases} - (r_i^k)^2 \leq 0, & r_i^k \leq 0 \\ - x_i^k (r_i^k)^2 \leq 0, & r_i^k > 0, \end{cases}$ 因为 $x_i^k \geq 0$ 。

搜索方向下降

- 因为 $p^k = \begin{pmatrix} -(B^k)^{-1} N^k p_N^k & p_N^k \end{pmatrix} \neq 0$ ，因此 $p_N^k \neq 0$ 。
- 由 p_N^k 的定义，可知 p_N^k 的各项（ r_i^k (18a)，及 $-x_i^k r_i^k$ (18b)）不全为 0。（若(18a)的各项全为 0，则必有(18b)的某项不为 0。若(18b)的各项全为 0，则必有(18a)的某项不为 0。）
- 因此 $\nabla f(x^k)^T p^k < 0$ 。
- 至此，已经证明了 p^k 既是可行方向，又是下降方向。因此 (1) 得证。

要满足的K-T条件

- (2), (\Rightarrow)。将 MP 问题重写为:

$$\begin{array}{ll} \min & f(x) \\ \text{s.t.} & g_i(x) = -x_i \leq 0, \quad i = 1..n \\ & h_j(x) = a_j^T x = 0, \quad j = 1..m \end{array}, \text{ 其中 } a_j^T \text{ 为 } A \text{ 的第 } j \text{ 行。}$$

- 要证 x^k 为 K-T 点, 即要证明:

$$\begin{cases} \nabla f(x^k) + \sum \lambda_i^* \nabla g_i(x^k) + \sum \mu_j^* \nabla h_j(x^k) = 0 \\ \lambda_i^* g_i(x^k) = 0, \quad i = 1..n \\ \lambda_i^* \geq 0, \quad i = 1..n \end{cases}, \text{ 代入 MP 各项,}$$

$$\begin{cases} \nabla f(x^k) - \lambda^* + A^T \mu^* = 0 \\ (\lambda^*)^T x^k = 0 \\ \lambda^* \geq 0 \end{cases} \quad \circ$$

对K-T条件各项的解释

- $g_i(x^k) = -x_i \Rightarrow \nabla g_i(x^k) = -e_i$ ，其中 $e_i = (0 \ 1 \ \dots \ 0)^T$ 为第 i 项为 **1**，其余各项均为 **0** 的列向量。因此，

$$\sum_i \lambda_i^* \nabla g_i(x^k) = -\sum_i e_i \lambda_i^* = -I \lambda^* = -\lambda^*。$$

- $g_i(x^k) = -x_i \Rightarrow \lambda_i^* g_i(x^k) = -\lambda_i^* x_i$ 。

- $h_j(x^k) = a_j^T x^k \Rightarrow \nabla h_j(x^k) = a_j$ 。于是，

$$\sum_j \mu_j^* \nabla h_j(x^k) = \sum_j a_j \mu_j^* = (a_1 \quad a_2 \quad \dots \quad a_m) \begin{pmatrix} \mu_1^* \\ \mu_2^* \\ \vdots \\ \mu_m^* \end{pmatrix} = A^T \mu^*。$$

要满足的K-T条件

- 按照 $x^k = \begin{pmatrix} x_B^k \\ x_N^k \end{pmatrix}$ 的划分, 重新表示 $\lambda^* = \begin{pmatrix} \lambda_B^* \\ \lambda_N^* \end{pmatrix}$, $\mu^* = \begin{pmatrix} \mu_B^* \\ \mu_N^* \end{pmatrix}$ 。
- 于是 x^k 要满足的 **K-T** 条件可重写为:

$$\nabla_B f(x^k) - \lambda_B^* + (B^k)^T \mu^* = 0, \quad (1)$$

$$\nabla_N f(x^k) - \lambda_N^* + (N^k)^T \mu^* = 0, \quad (2)$$

$$(\lambda_B^*)^T x_B^k = 0, \quad (3)$$

$$(\lambda_N^*)^T x_N^k = 0, \quad (4)$$

$$\lambda_B^* \geq 0, \quad (5)$$

$$\lambda_N^* \geq 0. \quad (6)$$

x^k 满足K-T条件

- 由已知, $p^k = 0$ 。于是 $p_N^k = 0$ 。
- 由(18a), $\forall i \in \text{index}(N^k)$, 当 $r_i^k \leq 0$ 时 $p_i^k = -r_i^k$ 。 $p_N^k = 0$ 表明 r_i^k 不能严格小于 0。因此有 $r_N^k \geq 0$ 。 (7)
- 由 p_N^k 的定义 (18a, 18b), $p_N^k = 0$ 表明 $\forall i \in \text{index}(N^k)$, 或者 $r_i^k = 0$, 或者 $x_i^k r_i^k = 0$, 二者必居其一。因此,
 $(r_N^k)^T x_N^k = 0$ 。 (8)
- 定义 $\lambda_B^* = 0$, $\lambda_N^* = r_N^k$, $\mu^* = -B^{k,T,-1} \nabla_B f(x^k)$, (9a, 9b, 9c)
其中 $B^{k,T,-1} = \left((B^k)^T \right)^{-1}$ 。
- (9a) \Rightarrow (3), (9b), (8) \Rightarrow (4), (9a) \Rightarrow (5), (9b), (7) \Rightarrow (6)。

x^k 满足K-T条件

- 由(9a)和(9c), 可知

$$\begin{aligned}\nabla_B f(x^k) - \lambda_B^* + (B^k)^T \mu^* &= \nabla_B f(x^k) + (B^k)^T (-B^{k,T,-1} \nabla_B f(x^k)) \\ &= \nabla_B f(x^k) - \nabla_B f(x^k) = 0, \quad (1) \text{成立}.\end{aligned}$$

- 由(9a), (9c), 以及 r_N^k 的定义,

$$\begin{aligned}&\nabla_N f(x^k) - \lambda_N^* + (N^k)^T \mu^* \\ &= \nabla_N f(x^k) - \left[- \left((B^k)^{-1} N^k \right)^T \nabla_B f(x^k) + \nabla_N f(x^k) \right] + (N^k)^T (-B^{k,T,-1} \nabla_B f(x^k)) \\ &= \nabla_N f(x^k) + (N^k)^T B^{k,-1,T} \nabla_B f(x^k) - \nabla_N f(x^k) - (N^k)^T B^{k,T,-1} \nabla_B f(x^k) \\ &= 0, \quad (2) \text{成立}.\end{aligned}$$

- 综上, 可知 x^k 满足 **K-T** 条件。
- 类似的证明, 可知(2)的(\Leftarrow)成立。□

确定 t_k 的上界 t_k^{\max}

- 由定理 4.5.3 的证明, $t_k > 0$ 要取为适当小的一个数。问题:
 t_k 需要小到什么界以内?
- 由新的探索点 x^{k+1} 的定义, 有 $x_i^{k+1} = x_i^k + t_k p_i^k$, $i = 1..n$ 。
- t_k 的选择要保证 $x_i^{k+1} \geq 0$ 。
- 对于 $p_i^k \geq 0$ 的 i , 则由 $x_i^k \geq 0$, $t_k \geq 0$, 已有 $x_i^{k+1} \geq 0$ 。
- 对于 $p_i^k < 0$ 的 i , 应要求 $t_k \leq -\frac{x_i^k}{p_i^k}$ 。
- 综上,
$$t_k^{\max} = \begin{cases} +\infty, & p^k \geq 0 \\ \min\left\{-\frac{x_i^k}{p_i^k} \mid p_i^k < 0, i = 1..n\right\}, & \text{存在 } p_i^k < 0 \end{cases}$$

Wolfe简约梯度法

(参数 $\varepsilon > 0$ 为终止误差。)

- 1 选取初始可行点 x^0 , $k \leftarrow 0$ 。
- 2 **while true do**
- 3 定义 x^k 的前 m 个最大分量的基变量。
- 4 计算简约梯度 r_N^k 。
- 5 按(18)(19)式构造可行下降方向 p^k 。
- 6 **if** $|p^k| \leq \varepsilon$ **then** 停止迭代, 退出循环。
- 7 (一维搜索) 求解 $\min_{0 \leq t \leq t_k^{\max}} f(x^k + tp^k)$, 得到 t_k 。
- 8 $x^{k+1} \leftarrow x^k + t_k p^k$, $k \leftarrow k + 1$ 。
- 9 **endwhile**
- 10 **return** x^k 。